M1B1T2_Al1: Plataforma como servicio (PaaS) en AWS

Autor: Leandro Gutierrez

Este documento intenta dar respuesta a las actividades propuestas en el Modulo 1 Bloque 1 Tema 2 del Master en Big Data y Ciencia de Datos. En él se describirán cada uno de los enunciados postulados y los resultados obtenidos utilizando la plataforma Amazon AWS, su servicio RDS (Amazon Relational DataBase Service), y la base de datos relacional PostgreSQL.

Abril 29, 2024

Descripción

Has sido contratado como Data Engineer por una empresa dedicada al mundo del deporte. Dentro de su estrategia definida para los próximos años, está empezando un proyecto para migrar sus aplicaciones a la nube. Para ello, ha elegido Amazon Web Services (AWS) como proveedor de servicios en la nube.

La multinacional tiene en sus instalaciones una base de datos relacional PostgreSQL, donde almacenan resultados de diferentes deportes.

El CDO (Chief Data Officer) ha decidido migrar a AWS, utilizando el servicio Amazon RDS (Amazon Relational DataBase Service) por las ventajas que ofrece usar un servicio PaaS.

Para la migración, han hecho una exportación de las diferentes tablas a ficheros de texto. Una de ellas contiene los resultados de la Liga Española de fútbol.

Campo	Descripción	Valor Ejemplo
idPartido	Identificador del partido	1
temporada	Temporada	1970-71
Jornada	Jornada	1
EquipoLocal	Nombre del equipo local	Athletic Club
EquipoVisitante	Nombre del equipo visitante	Barcelona
golesLocal	Goles del equipo local	1
golesVisitante	Goles del equipo visitante	1
fecha	Fecha del partido	12/09/1970
timestamp	Timestamp del registro	21942000.0

Sección AWS RDS

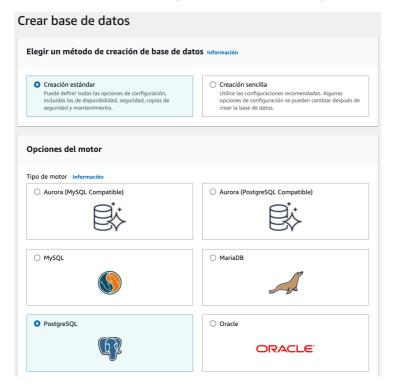
- Crear una base de datos PostgreSQL en AWS utilizando el servicio Amazon RDS.
- Una vez creada la base de datos, crear una tabla para almacenar los datos.
- Importar los datos del archivo "Partidos.txt" en la tabla creada.

Procedimiento

 Una vez iniciado el laboratorio desde https://awsacademy.instructure.com y habiendo ingresado a la plataforma AWS, nos dirijimos al servicio Amazon RDS el cual nos brinda la capacidad de iniciar una base de datos relacional en la nube de manera sencilla.



• Una vez dentro del servicio RDS, seleccionamos la opcion "Crear Base de Datos", aquí debemos seleccionar el motor que estemos necesitando, en nuestro caso utilizaremos **PostgreSQL**

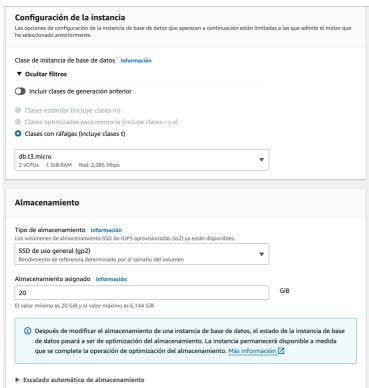


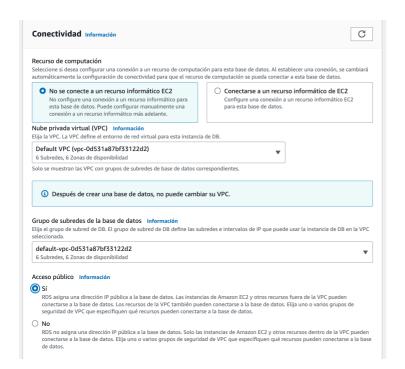
• Dentro de las configuraciones de nuestra DB PostgreSQL, vamos a seleccionar la plantilla **Capa gratuita**, la cual preconfigurará ciertos parametros para adaptarlos a nuestro caso de uso.



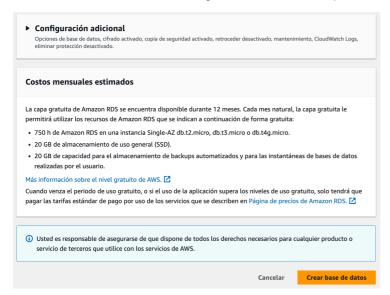
• Siguiendo con las configuraciones de nuestra base de datos, los demás parametros de configuración deben quedar como se muestra en las siguientes capturas de pantalla



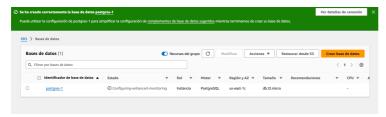




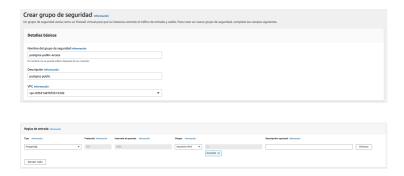
• Una vez seteadas las configuraciones mostradas, damos en Crear base de datos



• Esta accicón nos llevará de nuevo al panel principal de RDS, donde al cabo de unos minutos veremos la siguiente notificación y tendremos lista nuestra instancia



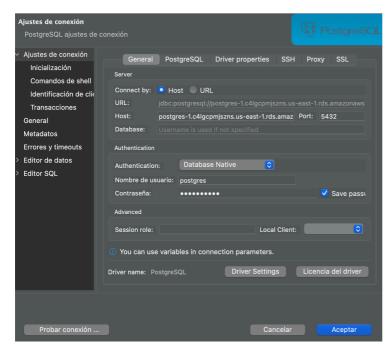
 Para poder acceder desde fuera de la infraestructura cloud de AWS necesitaremos configurar el firewall de nuestra instacia de Postgres, para ello crearemos un **Grupo de seguridad** en el cual indicaremos que vamos a habilitar el acceso al puerto donde está corriendo nuestra base de datos (TCP:5432). Esto lo conseguimos creando una regla de entrada dentro de nuestro grupo de seguridad.



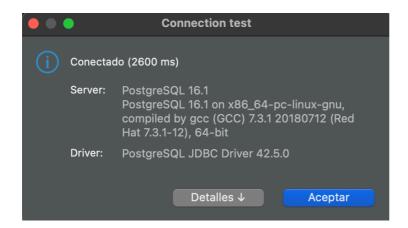
• Quedando nuestra Grupo de seguridad como muestra la siguiente captura de pantalla



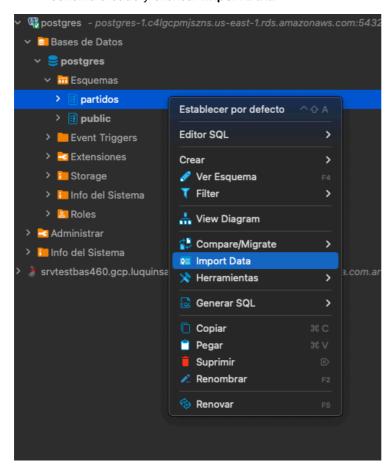
- Ahora si ya tenemos configurada y accesible nuestra base de datos Postgres en Amazon.
- Para conectarnos de manera remota utilizaremos DBeaver como cliente SQL, configurando la conexión en función de los datos que AWS nos provea y de las credenciales que hayamos utilizado durante la creación de la instacia



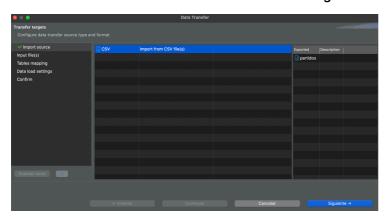
• Testeamos que tengamos conectividad y deberiamos ver el siguiente mensaje de éxito

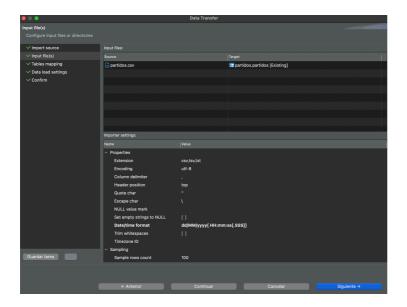


 Una vez conectados a la DB lo proximo será importar los datos, para ello lo primero será crear un schema, en este caso lo llamé partidos, luego debemos hacer click secundario sobre nuestro schema creado y clickear Import Data



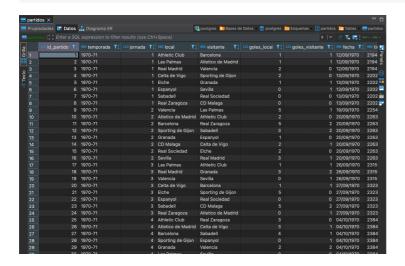
• En la nueva ventana que se abre debemos seleccionar CSV y buscar nuestro archivo. **NOTA: como** paso intermedio edité el archivo modificando el separador original por comas (,) y agregué la cabecera con los nombres de las columna segun indica el enunciado





• Culminada la importación, hacemos un checkeo de los datos con una consulta sencilla

SELECT * FROM partidos



Sección SQL

Ejercicio 1

¿Cuántos goles ha marcado el Barcelona?

SQL

```
SELECT SUM(CASE

WHEN local = 'Barcelona' THEN goles_local

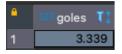
ELSE goles_visitante

END) as goles

FROM partidos.partidos p

WHERE local = 'Barcelona' OR visitante = 'Barcelona';
```

Resultados



Respuesta

El Barcelona a marcado un total de 3.339 goles.

Ejercicio 2

¿Cuántos partidos han terminado 0-0?

SQL

```
SELECT COUNT(1)
FROM partidos.partidos p
WHERE goles_local = 0 AND goles_visitante = 0;
```

Resultados



Respuesta

En el dataset encontramos un total de **3.511** empates 0-0.

Ejercicio 3

¿En qué temporada se han marcado más goles?

SQL

```
SELECT temporada,
SUM(goles_local + goles_visitante) as goles
FROM partidos.partidos p
GROUP BY temporada
ORDER BY goles DESC
LIMIT 1;
```

Resultados



Respuesta

La temporada 2012-13 es la que mas goles registró, con un total de 2.224

Ejercicio 4

¿Cuál es el equipo que tiene el record de meter más goles como local? ¿Y cómo visitante?

SQL

```
WITH goles_local AS(
    SELECT local AS equipo,
            SUM(goles_local) goles,
            DENSE_RANK() OVER(ORDER BY SUM(goles_local) DESC) AS ranking
    FROM partidos.partidos p
    GROUP BY local
), goles_visitante AS(
    SELECT visitante AS equipo,
            SUM(goles_visitante) goles,
            DENSE_RANK() OVER(ORDER BY SUM(goles_visitante) DESC) AS ranking
    FROM partidos.partidos
    GROUP BY visitante
SELECT 'como local' AS "goleador", equipo, goles, ranking
FROM goles_local gl
WHERE ranking = 1
UNION ALL
SELECT 'como visitante', equipo, goles, ranking
FROM goles_visitante gv
WHERE ranking = 1;
```

Resultados



Respuesta

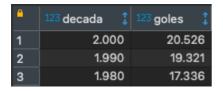
El **record de goles como local** se lo lleva el **Real Madrid** con un total de **2.054** goles convertidos. Mientras que el **record de goles como visitante** lo comparten **el Real Madrid y el Barcelona** con un total de 1.296 goles marcados fuera de casa.

Ejercicio 5

¿Cuál son las 3 décadas en las que más goles se metieron?

SQL

Resultados



Respuesta

Las decadas de los **2000, 1990 y 1980** son las que lideran la estadística de mayor cantidad de goles por temporada.

Ejercicio 6

¿Qué equipo es el mejor local en los últimos 5 años?

SQL

Resultados

```
ABC equipo 123 ganados_total 1 Barcelona 82
```

Respuesta

El **Barcelona** es el equipo que registra la mayor cantidad de partidos ganados como local, con un total **82 partidos** en las últimas 5 temporadas de las que se tienen datos.

Ejercicio 7

¿Cuál es la media de victorias por temporada en los equipos que han estado menos de 10 temporadas en 1ª división?

El resultado tiene que ser una tabla con dos columnas: Equipo | Media de victorias por temporada

SQL

```
WITH victorias_local AS (
    SELECT local equipo,
            temporada,
            SUM(CASE
                    WHEN goles_local > goles_visitante   THEN 1
                END) ganados
    FROM partidos.partidos p
    GROUP BY local, temporada
), victorias_visitante AS (
    SELECT visitante equipo,
            temporada,
            SUM(CASE
                    WHEN goles_visitante > goles_local    THEN 1
                    ELSE 0
                END) ganados
    FROM partidos.partidos p
    GROUP BY visitante, temporada
SELECT vl.equipo,
        SUM(vl.ganados+vv.ganados)/COUNT(1) media
FROM victorias_local vl
INNER JOIN victorias_visitante vv ON vv.equipo = vl.equipo AND vl.temporada = vv.temporada
GROUP BY vl.equipo
HAVING COUNT(1) < 10
ORDER BY equipo ASC;
```

Resultados



Nota: la imagen muestra los primeros 20 equipos en orden alfabético que no jugaron mas de 10 temporadas en primera y sus respectivas medias de victorias

Respuesta

El listado de la imagen superior muestra los equipos que no llegaron a jugar mas de 10 temporadas en primera, el total de equipos en esta situación es de 58.

Ejercicio 8

¿Quién ha estado más temporadas en 1ª División: Barcelona o Real Madrid?

SQL

```
SELECT local,
COUNT(DISTINCT temporada)
FROM partidos.partidos
WHERE local IN ('Barcelona', 'Real Madrid')
GROUP BY LOCAL;
```

Resultados



Respuesta

Tanto Real Madrid como Barcelona jugaron 45 temporadas en 1ra, según los datos que se tienen.

Ejercicio 9

¿Cuál es el record de goles como visitante en una temporada del Real Madrid?

SQL

```
SELECT visitante,
temporada,
SUM(goles_visitante) goles
FROM partidos.partidos p
WHERE visitante = 'Real Madrid'
GROUP BY visitante, temporada
ORDER BY goles DESC
LIMIT 1;
```

Resultados



Respuesta

En la temporada **2011-12** el **Real Madrid** convirtió su **record de goles como visitante** en una única temporada, con un total 51 goles marcados fuera de casa.

Ejercicio 10

¿En qué temporada se marcaron más goles en Cataluña?

SQL

```
WITH goles_bcn AS (
    SELECT local equipo,
            temporada,
            SUM(goles_local+goles_visitante) total_goles,
            SUM(goles_local) goles_hechos,
            SUM(goles_visitante) goles_recibidos
    FROM partidos.partidos p
   WHERE local IN ('Barcelona', 'Espanyol')
    GROUP BY local, temporada
), mejor_temporada AS (
    SELECT temporada,
            SUM(total_goles) total_goles,
            SUM(goles_hechos) total_goles_hechos,
            SUM(goles_recibidos) total_goles_recibidos
    FROM goles_bcn
    GROUP BY temporada
   ORDER BY total_goles DESC
    LIMIT 1
), total AS (
    SELECT 1 orden, m.temporada, g.equipo, g.goles_hechos, g.goles_recibidos, g.total
    FROM goles_bcn g
    INNER JOIN mejor_temporada m ON m.temporada = g.temporada
   UNION
    SELECT 2 orden, temporada, 'Total', total_goles_hechos, total_goles_recibidos, to
   FROM mejor_temporada
   ORDER BY orden
SELECT temporada, equipo, goles_hechos, goles_recibidos, total_goles
FROM total;
```

Resultados



Respuesta

En la temporada **2011-12** fué en la que se convirtieron mas goles en **Catalunya**. Fueron un total de **139 goles**, de los cuales **55** se dieron durante encuentros del **Espanyol** (31 marcados + 24 recibidos) y **84** durante partidos del **Barcelona** (73 marcados + 11 recibidos).